

1 From Analog media to Digital Sampling

1.1 模拟音频技术的历史

1.1.1 唱片 record player

- 唱片主要由 turnable(转盘), tonearm(唱臂), stylus(唱针) 三个部分组成
- 唱片上, 唱臂的末端唱针是如何还原唱片的声音
 1. When the record is rotated, tiny indentations in the walls of the groove moves the stylus.
 2. Movements of the stylus create a fluctuation in the electromagnetic field that induces an electric current in a coil.
 3. This current is sent to the amplifier, which reproduces the original sound.
- Hi-Fi(high fidelity 高保真) is used to provide faithful sound reproduction.
- 黑胶唱片 (vinyl records) 缺点
 1. It is difficult to keep records scratch free which produces popping noises(唱片划痕会产生噼啪声).
 2. Groove lock causes sections to repeat over and over again.(纹道卡滞导致部分内容反复播放)
 3. Records warp if is close to a heat source making them unplayable.(唱片若放在热源附近可能会翘曲, 导致无法播放)

1.1.2 Tape/磁带/cassette

- 缺点
 1. Cassette has slow recording and playing speed.
 2. Cassette has narrow tracks.
 3. Cassette has limited fidelity.

1.2 数字音频的存储 storing digital audio

- 存储设备
CDs, hard drives, solid-state memory.
- 声卡 (sound card)
 1. From analog input to digital output(从模拟输入到数据输出)
 - 模拟输入 (analog input)
 - 抗混叠滤波 (anti-aliasing filter)
 - 采样
 - 量化 (Quantization)
 - 数字输出 (digital values store in the computer)
 2. sample rate (采样率) 和 number of bits(位数)
 3. 录音时注意声卡的输入电平, 输入信号过强 (输入信号 overload-ing 过载), 信号顶部波形导致削波, 造成失真。

1.3 Clipping 削波

- 定义: 削波 is a form of amplitude distortion where the signal peaks are clipped off.
- 削波会导致波形的改变, 波形改变会影响 timbre(音色)。削波也会导致额外的 distortion harmonics 失真谐波。
- Hard clipping(硬削波) VS soft clipping(软削波)
 1. 硬削波是当信号超过数字系统所能处理的最大电平时, 其高于最大电平的部分将会被完全截断, 产生一个平坦的顶部。硬削波将会为 digital recording 引入 harsh unpleasant quality.
 2. 软削波是当信号幅度接近或超过阈值时, 其增益会被平缓地渐进地降低, 波形顶部被圆滑地压缩。软削波是以饱和 (saturation) 的形式呈现。

1.4 analog saturation

saturation rounds the corners of the waveform. 饱和使波形的棱角更加圆滑。

1.5 sampling rate 采样率

1.5.1 采样率

- 定义：采样率是声卡中模数转换器每秒采集的音频信号样本数。
- Hertz(Hz) 为单位，典型值为 44.1kHz, 48kHz, 96kHz, 192kHz。
- 441000Hz 来源 (technical 技术, psychoacoustics 心理声学):
 1. 视频 1s 的帧数 * 采样线数量 * 每条线存储的样本数 = $60 * 245 * 3 = 44100$
 2. 人类能听到 20Hz 到 20KHz 之间的频率，因此也不需要更高的采样频率了。
- 48kHz 常用于 professional audio situation.
- 8kHz 低采样率主要用于 speech signals。
- 高采样率可以获得更多的高频信息，获得更好的音质；但是意味着更多的样本，更多的数据，需要更多的存储空间，更多的数据要被处理

1.5.2 Shannon's Theorem 香农定理

定义：若信号的最高频率不大于采样频率的一半，则可以从采样样本中精确重建任何信号。 $f_{max} \leq F_s/2$ 。 f_{max} 为信号最高频率， F_s 为采样频率。 $F_s/2$ 也被称为 Nyquist frequency.

1.5.3 Anti-Aliasing Filter 抗混叠滤波器

由于一个信号是由很多信号组成。抗混叠滤波器被用于抑制信号中高于奈奎斯特频率的信号成分。

2 Quantization and Compression 量化和压缩

2.1 Quantization

2.1.1 bits 位数

用于表示 analog value 的位数 (bits) 越多, 对原始波形的表示越精确。bits 通常以 2^n 级增长。

- bit depth 比特深度对声音采样的位数。更多的比特位数意味着更多的存储空间, 位深越大, 数字信号振幅变化越细微。

2.1.2 Signal noise ratio(SNR) 信噪比

定义: 信噪比是正确的 (pure) 的信号功率与由于量化过程所引入噪声的功率之比。 $SNR = P_{signal}/P_{noise}$

- SNR 是信号质量的指标, 单位为 decibel(dB)
- dB 是无量纲单位, 用于描述两种现象的相对功率/强度。
- 信噪比取决于信号选择的位深度。任何以给定比特深度编码的信号都将具有相同的信噪比。
- 如何得到量化后的噪声?

具体来说, 我们画出模拟信号的时域图, 以及量化后信号时域图, 模拟信号与量化信号中间缺少的面积, 就是量化噪声

2.2 Dynamic Range 动态范围

dynamic range 是在给定比特深度下可表示的音频信号最大振幅和最小振幅的比值。但是一般来说将本底噪声作为最小振幅即可, 因为信号的最小振幅比本地噪声信号更低。

以下为理想情况下信噪比和位深公式 $SNR_{db} = 6.02_{db} * Nbits + 1.76_{dB}$
16bits->89dB, 但是制作者会对音频进行动态压缩处理使音频中最安静和最响亮之间的差异减小, 提高音频整体音量, 但是失去音频的细腻感 (subtlety)。

- 声卡的最大允许振幅不受动态范围 (位深) 的影响

-

2.2.1 Sensitivity of the ear 人耳的灵敏度

- 人耳的频率范围大概 20Hz 到 20kHz，对 2 到 4kHz 最敏感，动态范围大概 96dB
- 大致疼痛阈值：130dB；听力损伤：>90dB；正常对话 60-70dB
- 正常听力范围约为 500Hz 至 2kHz，低频为元音和低音，高频是辅音

2.2.2 Loudness 响度

- 响度是整个录制波形的平均电平，取决于一段时间内测得的音量。改变录音的响度会改变录音的动态范围，

2.3 音频存储格式

2.3.1 Wav Files

- Wav(Waveform audio files)

优点：WAV 是一种为专业音频制作设计的、无压缩且完全无损的格式，通过脉冲编码调制技术提供最高音质和最佳编辑性能，

缺点：但是文件体积大，不能提供像 FLAC 格式丰富的元数据标签，且最初 for window，现在都可以。

WAV is a standard format in professional audio. It is designed to be uncompressed and completely lossless, utilizing Pulse Code Modulation technology to deliver the highest sound quality and optimal performance for post-production editing, at the cost of very large file sizes.

- AIFF(Audio interchange file format)

AIFF 是一种为专业音频制作设计的、无压缩且完全无损的格式，通过脉冲编码调制技术提供最高音质和最佳编辑性能，但是文件体积巨大，最初 for Mac。

- MP3(MPEG-2 Audio Layer III)

MP3 是有损压缩, 通常人们无法听到极高频率的细节, 因此高频部分信号会先考虑被压缩。

- 优点: MP3 是有损压缩, 将文件大小压缩到更 compact level, 可在移动设备或者消息传播中使用。通常压缩音频的高频部分以及冗余声音。
- 缺点: MP3 压缩会丢失音频的部分信息, 降低音频质量, 如果是吉他等乐器, 过度压缩会使音频失真。

- M4A(MPEG-4)

M4A 是有损压缩, 使用 Advanced Audio Coding(AAC) 进行编码, 提供与 MP3 相同的比特率并且压缩率更高。

- FLAC(Free lossless audio codec 自由无损音频编解码器)

优点: FLAC 是无损压缩, 音频质量好, 并且数据大小为 CD 的一半, 对许多设备均兼容。缺点: FLAC 文件大小比 MP3 大 6 倍。

M4A 是有损压缩, 使用 Advanced Audio Coding(AAC) 进行编码, 提供与 MP3 相同的比特率并且压缩率更高。

3 Frequency Analysis 频率分析基础 1

3.1 Fourier Theory 傅立叶理论

任何周期性函数 $f(t)$ 都可以通过一系列频率不断增加的正弦项和余弦项的总和来构成。

3.1.1 不同的波形

- sawtooth 锯齿波

含基波和所有整数倍的谐波

- square wave 方波

含基波和奇次谐波, 第 n 个奇次谐波的振幅 $= \frac{1}{n} \times$ 基波振幅

- Triangle wave 三角波
含基波和奇次谐波，第 n 个奇次谐波的振幅 $= \frac{1}{n^2} * \text{基波振幅}$
- Double triangle wave 双三角波
- Parabola signal

3.1.2 Fourier Transform 傅立叶变换

$$\text{公式: } F(\omega) = \int_{-\infty}^{\infty} f(t)e^{-j\omega t} dt$$

ω 是角频率 (radian frequency), $f(t)$ 是时间信号 time signal, $e^{-j\omega t}$ 是复指数函数。

$$\text{等价于: } F(\omega) = \int_{-\infty}^{\infty} f(t)(\cos(\omega t) - j\sin(\omega t)) dt$$

复指数函数可以描述单独使用相位为 0 的正弦函数或者余弦函数所不能描述的周期性函数，复指数函数由余弦和正弦波共同组成。

3.1.3 phase 相位

$$\text{相位的移动相当于时间的偏移 } x(t - \tau) = \sin(\omega(t - \tau)) = \sin(\omega t + \phi)$$

4 Frequency Analysis 频率分析基础 2

4.1 Fourier transform

- 本质：测量波形 $f(t)$ 与频率为 ω 的各余弦波 $\cos(\omega t)$ 和正弦波 $\sin(\omega t)$ 之间的相似度。
- 通过傅立叶变换公式，将 $e^{j\omega t}$ 通过欧拉公式变为 $\cos(\omega t) - j\sin(\omega t)$ 后与信号 $f(t)$ 相乘，对于每一个时间点幅值，如果信号和 $\sin/\cos$ 相似度大，那么乘积也大；若相似度小，乘积接近 0，比如一个在顶峰，但是另一个在 0 附近，那么乘起来接近 0。正数负数不影响，数值代表能量。
- 因此傅立叶变换本质上衡量信号 $f(t)$ 与频率 ω 处的复指数信号之间的相似度。

4.2 Frequency spectrum 频谱

频谱 $F(\omega)$ 是信号 $f(t)$ 经傅立叶变化后的结果。对于每一个选定的频率 ω , 复数 $F(\omega)$ 的值量化了信号 $f(t)$ 中含有该频率成分的幅值 (复数的实部) 和相位 (角度值, 相当于负数的虚部)。频谱就是信号在所有频率点上的成分含量分布图。

- 复数 $F(\omega)$ 的幅值: $|F(\omega)| = \sqrt{\text{real}(F(\omega))^2 + \text{imaginary}(F(\omega))^2}$
- 复数 $F(\omega)$ 的相位: $\theta = \tan^{-1}(\frac{\text{Imaginary}(F(\omega))}{\text{Real}(F(\omega))})$
- magnitude spectrum 幅值谱: 信号中各个频率成分的强度 (能量) 分布
- phase spectrum 相位谱: 各频率成分在时间轴上的相对起始位置
- 我们更关注一个音频中频率成分的强度: 对于一个可听见的频率成分, 其幅值大小决定了我们的感知响度。
- 正负频率:
 1. 一个正弦波可以分解为两个旋转的复指数 (正频率成分和负频率成分) 之和 $A\sin(\omega t) = A(\frac{e^{j\omega t} - e^{-j\omega t}}{2j})$
 2. $A\cos(\omega t) = A(\frac{e^{j\omega t} + e^{-j\omega t}}{2})$

4.3 Continuous-Time Fourier Transform(CTFT) 连续傅立叶变换

- Continuous-Time Fourier Transform 公式: $X(\omega) = \int_{-\infty}^{\infty} x(t)e^{-j\omega t} dt$
- inverse CTFT 公式: $x(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} X(\omega)e^{j\omega t} d\omega$
- 在连续傅立叶变换中, 时间变量为 t (单位是 s), 频率变量为 ω (单位为弧度 radians)

4.4 Discrete Fourier Transform(DFT) 离散傅立叶变换

连续傅立叶变换 = 离散傅立叶变换求和

- Continuous-Time Fourier Transform 公式:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} kn}, k=0,1,\dots,N-1$$

- inverse DFT 公式:

$$x[n] = \frac{1}{N} \sum_{k=0}^{N-1} X[k] e^{j \frac{2\pi}{N} kn}, n=0,1,\dots,N-1$$

- 离散傅立叶变换中, 时间为样本索引 n , 频率为 frequency bin index k 。
- 赋予 n 和 k 物理意义

1. 假设采样周期 T_s , 隔多少秒采样一次, $t_n = n * T_s$
2. 假设采样频率 $f_s = \frac{1}{T_s}$, 表示每一秒采样几个点。
3. 在 N 点的 DFT 中, $f_k = k * \frac{f_s}{N}, \frac{f_s}{N}$ 表示你可以把这 N 个采样点分得有多细 (比如你的眼睛能看到 60Hz, 你要观察 600Hz, $60/600=0.1\text{Hz}$, 那么 600 被你分成了每次观察 0.1Hz, 随着 N 得增大, 相当于你观察得更加精细了)。
4. $f_k = k * \frac{f_s}{N}$ 表示第 k 个点的物理频率。
5. 公式: $X(f_k) = \sum_{n=0}^{N-1} x(t_n) e^{-j2\pi f_k t_n}$

4.5 Fast Fourier Transform 快速傅立叶变换

- 应用
 1. 解决 DFT 潜逃循环效率低的问题, 加速计算
 2. 信号长度为 2 的幂时效果好, 若 N 为质数则无性能提升

4.6 FFT 代码演示步骤

- 频谱重排
- FFT 计算
- 频谱特征计算

4.7 Windowing

4.7.1 引入

- 离散信号频谱推论：频谱是以采样率 F_s 为周期的无限周期函数。假设信号本身频率为 f_0 ，那么频谱会在 $f_0 + \pm F_s, f_0 + \pm 2F_s$ 出现峰值。
- 1024.5Hz 不是 FFT 的频率箱（间隔是 1Hz，没有 0.5Hz 的箱），此时信号的周期不是“采样点数的整数倍”，信号在“FFT 的输入长度内”是不完整周期，因此开头和结尾无法衔接。
- 当信号频率恰好等于 FFT 的某一个频率箱时，信号在 FFT 输入长度内是完整周期，波形首尾连续；当信号频率不在频率箱上时，信号是不完整周期，波形首尾断裂——这会导致后续的频谱出现“泄漏”（能量分散到多个频率点）。

4.7.2 window function

窗函数通过截取信号的有限时间片段来进行傅里叶变换和相关分析。通过“原始信号”和“窗函数”逐点相乘（改变信号形状，改变信号频谱，新的频谱是信号频谱和窗函数的卷积），让信号在 FFT 的输入长度内从 0 平滑开始、到 0 平滑结束

- Rectangular window
- Hanning window
- Kaiser window

4.7.3 Convolution 卷积

公式 $y[n] = \sum_{k=0}^{N-1} h[k]x[n-k]$, y 是信号 x 与卷积核 h 的卷积结果

5 Frequency Analysis 频率分析 3

5.1 Window function

- 在计算频谱时，使用窗函数来消除信号两端不连续性。
- 使用矩形窗可以获得尖锐的峰值，但是底部会有大量杂波

- 使用 half-cosine 窗口 (比如 hanning) 会得到更宽的峰值, 减少杂波数量。

5.1.1 加窗处理 +DFT

- 公式: $X[k, n_0] = \sum_{m=n_0-N+1}^{n_0} w[m - n_0]x[m]e^{(-2\pi k/N)m}, k=0,1,2,\dots,N-1$
- 窗口 $w[m-n_0]$ 为一个 low-pass filter impulse(窗为低通滤波器, 因为对于变化缓慢的信号, 可以对其波形完整保留, 相当于放行低频信号) response, 通过傅立叶变化中心频率变为 $(k/N)F_s$, 变为带通滤波器 (留中间频率, 阻挡高频和低频)

5.1.2 Rectangular window

- 公式: $w[n] = \begin{cases} 1, & 0 \leq n \leq N-1 \\ 0, & \text{otherwise} \end{cases}$
- 矩形窗中, 其频谱比要测量的每个频率分量的宽度更宽, 那么其他频率分量也会泄漏到计算中, 频谱表示会受到影响。因此我们要减小矩形框旁瓣信号的影响。

5.1.3 Hanning window

- 公式: $w[n] = \begin{cases} 0.5[1 - \cos(\frac{2\pi n}{L})], & 0 \leq n \leq N-1 \\ 0, & \text{otherwise} \end{cases}$
- 通带宽度通常为: $2\pi(\frac{4}{L})$
- $\text{FrequencyResolution} = \frac{2}{L} f_s \text{Hz}$
- $\text{TimeResolution} = \frac{L}{2} T_s \text{sec}$

5.1.4 Hamming window

- 公式: $w[n] = \begin{cases} 0.54 - 0.46\cos(\frac{2\pi n}{L}), & 0 \leq n \leq N-1 \\ 0, & \text{otherwise} \end{cases}$

5.1.5 spectrogram parameter 频谱图参数

- Window length(窗口长度): 窗口长度决定 the width of its passband, 进而影响 frequency resolution. 如果 L 很大, 平均更长时间的信号, 短暂的时间细节将会被抛弃, 频率分辨率会提升 (uncertainty principle)。
- The number of analysis frequencies N (总数据长度)

5.2 Zero padding 零填充

- 零填充是给信号末尾补 0 的操作
 1. 适配快速傅立叶变换中信号长度为 2 的 N 次方长度的要求, FFT 算法在处理 2 的幂次方长度的信号速度会更快, $N\log N$
 2. 让 FFT 的结果更加平滑: 补 0 后 FFT 输出点数更多, 频谱图看起来更连续。
 3. 但是补 0 不会提升真实的频谱分辨率, 频谱分辨率之和原始信号的有效长度有关。

5.3 spectrogram 频谱图

- 思想: 由于有些信号是非周期性的且长度很长, 因此将长信号分解成小片段, 并使用快速傅立叶变换对每个片段进行傅立叶分析。
- 过程: 音频输入-> 缓冲输入帧-> 窗函数-> 快速傅立叶-> 幅值和功率-> 深度图

5.3.1 spectrogram principle

- 音频信号首先被缓冲为相互重叠的帧, 帧大小长度通常为 2 的幂次。
 1. 帧就是将很长的信号切成一段一段较短的时间块, 每一块称为帧
 2. 相互重叠的帧: 切分时, 下一帧的起点并不紧挨着上一帧的终点, 而是会往回退一部分, 与上一帧共享一部分相同的音频数据。原因是之后对每一帧进行加窗处理, 窗口函数会使帧两端的信号幅值被压的很低 (以避免边缘不连续而导致的频谱泄漏), 如果不让其重叠, 帧与帧之间会丢失大量信息。通常重叠帧长度的一半。

- 使用窗函数处理，消除帧边缘的不连续性。一般使用 hanning 窗。
- 进行 0 padding，提高频谱图的平滑度。
- 输入至 FFT 得到复数谱，计算平方幅值 (能量/功率分布)，将功率转换为 dB ($10\log_{10}(P_k)$)。
- 最后 FFT 序列显示为深度图。

5.3.2 sliding window 滑动窗口

- 滑动窗口的最小移动量为一个采样点。
- 但是如果信号的频谱不会随时间快速变化，我们可以跳过一些时间点，切不会丢失频谱图的基本形状。
- 滑动窗口每次移动几个样本被称为 hop size(跳跃大小)

6 speech signals and modeling Part1

语音信号的声音和过度是信息的符号表示。

6.1 语音信号的表示

- waveform representation(波形表示)
 1. 定义：保留模拟语音信号的原始波形形状，通过采样和量化将模拟信号转换为数字信号。
- parametric representation(参数表示)
 1. 定义：通过语音信号，提取发声模型的关键参数。
 2. 流程：
 - 使用数模转换器进行采样，获取数字波形表示
 - 通过进一步处理获取发声模型参数
 - 模型参数可进一步分类 (excitation parameters 激励参数 (与语音声源相关参数)/vocal tract response pattern 声道响应模式 (单个语音相关模式))

- 语音参数化表示的问题：
 1. speech is short time stationary(语音具有短时平稳性)
 2. 如何制定，选择合适的特征向量表示，以准确捕捉语音信号中的重要信息。

6.2 语音产生机制

6.2.1 发声机制

- The vocal tract (声道) is at the opening between vocal cords (声带), or glottis(声门) and ends at the lips.
- The nasal tract (鼻道) begins at the velum (软腭) and ends in the nostrils (鼻孔) .

- 鼻音的产生

When the velum is lowered, the nasal tract is acoustically coupled to the vocal tract to produce the nasal sounds of speech.

- The subglottal system(声门下系统) consists of lungs, bronchi(支气管), and trachea(气管). And the subglottal system serves as a source of energy for speech production.

- 语言的产生

Speech is the acoustic wave that is radiated from this system when air is expelled from lungs and the resulting flow of air is perturbed by a constriction somewhere in the vocal tract.

6.3 speech sound classes

6.3.1 voiced sound 浊音

Voiced sounds are produced by forcing air through the glottis with tension of the vocal cords adjusted so that they vibrate in a relaxation oscillation, thereby producing quasi-periodic pulses of air which excite the vocal tract.

6.3.2 Short vowel sounds 短元音

Short vowels are a group of monophthong sounds characterized by shorter duration compare to long vowels and diphthong.

6.3.3 Weak vowel sounds 弱元音

Weak vowels are found in unstressed syllables in English pronunciation. There are 4 weak sounds.

6.3.4 Reduced vowel sounds 弱化元音

Long sounds are shortened if the following sound is a voiceless consonant (清辅音) .

6.3.5 Diphthong 双元音

Diphthongs are long vowel sounds that start in one position of the mouse and end in another within the same syllable.

6.3.6 Long vowels 长元音

6.3.7 Nasal Consonant sounds 鼻音辅音

Nasal consonant sounds are made by blocking air in the mouse and releasing sound through the nose.

6.3.8 Fricatives 摩擦音

Fricative sounds are generated by forming constriction at some point in the vocal tract and forcing air through the constriction at a high enough velocity to produce turbulence.

7 speech signals and modeling Part2

7.1 4 other excitation types

7.1.1 Plosive 爆破音

The plosive sounds result from making a complete closure normally towards the front of the vocal tract, building up a pressure behind the closure and abruptly releasing it.

7.1.2 Plosive consonant 爆破辅音

The plosive consonant sounds are made by completely blocking the flow of the air as it leaves the body.

7.2 voice production 声音产生

7.2.1 基频

- 基音周期 F_o : The time between successive vocal fold openings is called fundamental period T_0 . (声带完成一次完整开合振动的循环所需要的时间)
- 发声的基频 T_o : The rate of the vibration is called fundamental frequency of the phonation. (每秒钟完成的开合振动循环次数)
- $F_o = \frac{1}{T_o}$

7.2.2 Pitch 音高

Pitch refers to the perceived fundamental frequency of a sound.

7.2.3 Fundamental frequency VS Pitch

1. Fundamental frequency is an objective and physical property of the sound wave. It is the actual rate at which the vocal folds vibrate.
2. Pitch is a subjective and perceived fundamental frequency of a sound.

7.2.4 Prosody 韵律

- Stress refers to a change in fundamental frequency and loudness to signify a change in syllable, word or phrase.

7.2.5 Formants 共振峰

- As the sound generated propagates down the tubes formed by vocal and nasal tracts, the frequency spectrum is shaped by the frequency selectivity of the tube. The resonance frequencies of the vocal tract tube are called formant frequencies or formants.
- The resonance frequencies of the vocal tract show up as dark bands (这些共振峰频率所在的位置, 因为能量强, 就会显示为水平方向的深色条纹。看这些条纹的位置, 就能知道发的是什么元音。)。
- Voiced region are characterized by a striated or narrow appearance due to periodicity in the waveform, while unvoiced intervals are more solidly filled in.

8 Speech Synthesis 语音合成 Part 1

8.1 Hourglass idea 沙漏思想

8.1.1 文本分析 Text analysis

- Text Normalization(文本规范化)
 1. 多个用户输入的原始文本, 将相同意思的文本转换为同一个表达
- Phonemic Analysis(音位分析)
 1. Phonemic 音位定义: 音位是语言系统中能区别词义的最小单位, /p/ 和 /b/ 是两个不同的音位。
 2. allophones 音位变体定义: 音位变体是某个音位在实际口语中具体表现出来的各种不同的物理声音, 是同一个音位在不同语音环境下的具体表现形式。
 3. The process of analyzing a spoken language to figure out:

- what its phonemes are
 - what the allophones are of those phonemes
 - what each allophone's distribution is
 - 这个过程又被称为 phonemicization of the language (语言的音位化)
- Prosodic Analysis(韵律分析) 韵律分析是基于语言在不同语境中的重音和语调模式, 是语法和意义分析的基础。
 1. 给定 string of phones
 2. prosody 分析
 - Desired F0 for the entire utterance (整个话语的期望基频)
 - The duration (时长) of each phone
 - Stress value for each phone and accent value
 - intensity

8.2 4 types methods for synthesised speech

8.2.1 Articulatory synthesis(发音合成)

Articulatory synthesis models the physics of the human speech production system. (发音合成模拟人类语言产生系统的物理机制) It models the movement of articulators like the lips, tongue, and glottis using biomechanical principles. And the data is derived from X-ray analysis of natural speech.

8.2.2 Formant synthesis 共振峰合成

Formant synthesis models the resonances of vocal tract by a linear speech model. (共振峰合成使用线性语音模型模拟了声道的共振峰) .

Formant synthesis generates speech by modeling the resonant frequencies (formants) of the vocal tract using a set of adjustable bandpass filters. A periodic source excites these filters to produce voiced sounds, while noise is used for unvoiced sounds. By controlling the formant frequencies and bandwidths, it can produce a wide range of speech sounds, though the output often has a characteristic mechanical quality.

- Resonator filter 谐振器滤波器

Resonator filter 是特殊的 IIR 滤波器，公式为：

$$H(z) = \frac{1}{1 - 2r\cos(\theta)z^{-1} + r^2z^{-2}}$$

1. $\theta = \frac{2\pi f}{F_s}$, 共振峰频率是 f, 采样频率是 F_s
2. 共振峰带宽 BW 与 r 相关联, $BW=2(1-r)$

- Rule-based formant synthesis (基于规则的共振峰)

可以通过制定一套规则确定使用共振峰合成器合成所需话语所必须的参数：

1. Voicing fundamental frequency (F0) 发声基频
2. Degree of voicing in excitation(VO) 激励发声程度
3. Formant frequencies and amplitudes($F_1, F_2, \dots, F_n; A_1, A_2, \dots, A_n$) 共振峰频率和振幅
4. Frequency of an additional low-frequency resonator (FN) 附加低频谐振器频率
5. Intensity of low- and high-frequency region 低频和高频区域强度

- Cascade formant synthesizer 级联共振峰合成器

1. A cascade formant synthesizer consists of band-pass resonators connected in series and the output of each formant resonator is applied to the input of the following one. 级联共振峰谐振器由一系列串联的带通谐振器组成并且每一个共振峰谐振器的输出被用于下一个谐振器的输入。

2. 优点：

- 元音的相对共振峰振幅不需要单独控制
- 适合生成 non-nasal voiced sounds (非鼻音浊音)

3. 缺点：

- 不可以产生 fricatives and plosive bursts.

- Parallel formant synthesizer 并联共振峰合成器

1. A parallel formant synthesizer consists of band-pass resonators connected in parallel. The excitation signal is applied to all formant simultaneously and their outputs are summed.
2. 优点:
 - The parallel structure enables controlling of bandwidth and gain for formant individually.
 - 适合生成 nasals, fricatives and stop-consonants. (适合生成鼻音, 摩擦音, 塞辅音)
3. 缺点:
 - 对比级联式共振峰合成器, 并行共振峰合成器产生的元音效果差。

8.2.3 Concatenative synthesis 拼接合成

Concatenative synthesis uses different length pre-recorded samples derived from natural speech.

- 核心概念:
 1. 录制语音库
 2. 检索合适的单元序列
 3. 拼接调整时长和音高获得更加自然的感受
 4. 生成波形
- 优点: 连接预先录制的自然话语是生成清晰且自然的合成语音最简单的方法。
- 缺点:
 1. 需要大量内存存储录制的声音
 2. 当声音无法衔接时, 出现声音不连贯的现象
 3. 每一个说话声音需要其本人自己的一系列录音
- 选择声音长度
选择最好的 unit length(单元长度): 要拼接在一起形成声音的语音单元的长度

1. 使用较长的语音单元由一个更高的自然度，更少的拼接点以及对协同发音 (coarticulation) 更好的控制，但是所需的单元数量和单元存储空间要更多。
 2. 单元越短，所需的存储越少，但是样本收集和标注过程会变得复杂，单元拼接过程中出现语音不连续性的问题可能性更大。
 3. 单位的选择包含了 words, syllables, demisyllables, phonemes, and diphones.
 4. word 词语单元的选择
 - 单词内的协同发音效应已经在单词中可以直接捕捉到了，词语的拼接相对容易执行
 - 单词拼接适合词汇量较小的场景，且连接独立的单词会让合成语音不自然。
 - 每个语言都有很多单词，数据量庞大。
 5. syllable 音节单元的拼接
 - 音节的数量少于单词
 - 音节需要模拟协同发音效应
 6. phoneme 音位的拼接
 - 音位的数量比音节更少，只有 44 个
 - 一些音位在单词中没有稳定的目标位置 (有多个音位变体)，比如爆破音，难以进行语音合成
 7. diphones 双音位的拼接
 - 双音位是两个相邻的音位：连接起来的位置从一个音位的中间沿伸到下一个音位的中间。
 - 双音位的长度为一个音位长度
 - 音位的中心位置是协同发音效果最显著的区域，是拼接波形的好位置。
- Diphone synthesis 双音位合成
 1. 录制一名说话者对每个双音位说一个例子
 2. 标记并切分每个双音位并创建双音位数据库

3. 合成一段文本，合成器将单词流分割成双音位序列，并在数据库中查找响应的双音速并将其连接起来，并且在双音位的边界处进行信号处理。
 4. 通过 pitch-synchronous overlap add(PSOLA) 改变双音位序列的 prosody(F0,energy,duration)，使语音听起来更自然。
 5. 优点
 - 双音位合成语音中，所需录制语音单元数量少
 - 双音位有助于减轻因协同发音效应引起的问题
 - 双音位接受细化调整音韵
 6. 缺点
 - 语音听起来比较单调
 - 双音位拼接点失真
 - 双音位合成适合发音规则一致性语音
- Unit Selection 单元选择合成
 1. 定义：通过构建包含双音位，音节，单词，短语，句子等语音单元的大规模标注语音数据库，在合成时检索并拼接最优语音单元，生成自然度更高的语音。
 2. 思想：优先复用完整度高的语音单元，减少拼接次数，同时利用大量数据覆盖更多语境。
 3. 特性：
 - (a) 多种语音单元，需要录制海量语音，存储消耗极大，CPU 消耗低，需要高效搜索算法
 - (b) 需要对数据进行大规模标注，包括语音波形，音位边界，韵律，语境等信息。
 4. 流程
 - 数据库构建
录制多位说话人的通用语音素材，标注单元边界、音位语境、韵律参数等，形成带标签等大型数据库。
 - 文本分析
对输入文本进行分词，音位转换，韵律预测 (确定重音，基频，时长)，形成目标合成参数

- 单元检索
通过最小化总代价 (目标成本 + 连接成本) 从数据库中筛选最优单元序列
 - 单元拼接
将选中的单元直接拼接, 输出合成语音
5. Target cost(目标成本)
- 衡量候选单元和目标合成参数的匹配度
 - 核心子成本: 重音, 短语位置, 基频, 音位时长, 词汇一致性
6. Join cost(连接成本)
- 衡量相邻候选单元拼接处的平滑度
 - 频谱特征一致性, 基频, 能量
7. 总成本公式 $\hat{u}_1^n = \arg \min_{u_1, \dots, u_n} [\sum_{i=1}^n C^{target}(t_i, u_i) + \sum_{i=2}^n C^{join}(u_{i-1}, u_i)]$
- t 为要合成的目标单元序列
 - u 为候选单元序列
8. 优点
- 单元选择合成的语音质量优于双音位合成, 因为可复用完整单词/词语, 保留真实语音的韵律。
 - 单元之间衔接次数减少, 减小不连续性
 - 韵律听起来更自然。
9. 缺点
- 局部质量不稳定, 数据库若缺乏匹配单元, 可能出现优质片段和劣质片段混合的情况。
 - 较高的计算复杂度, 需要高效搜索算法与最小化成本。
 - 灵活性低, 无法修改选中的单元信号, 数据库未覆盖的内容难以生成。

8.2.4 AI synthesis

- HMM Synthesis 隐马尔可夫模型

早期数据驱动型 AI 语音合成技术, 从训练数据中学习统计规律, 生成语音参数。

– 特征

1. HMM 是一种参数化模型，模型参数量小。
2. 数据兼容性强，可以用来自多个说话人的混合数据进行训练

– 模型核心逻辑

1. Hidden States: 每个 phoneme+context 都对应一个 HMM
2. 首先提取 acoustic feature: 基频，频谱，时长
3. 使用观测序列进行训练
4. 每个音状态输出声学特征，由于生成的声学特征具有不连续性，使用插值对不同基频的特征进行过渡调整，却把皮参数连续性。

– 训练过程

1. 使用数据库中的语音进行训练
2. 提取频谱参数，激励参数，
3. 标注输入数据
4. 训练 HMM

– 合成阶段

1. 输入文本，进行文本分析，得到音位语境标注，韵律标注等；
将标注传入 HMM 模型身材个很难过激励参数和频谱参数；
输入合成滤波器，合成语音

9 Speech Synthesis3: Text to Speech System

- Tokenization 分词：句子分割，标点处理，单词分割
- Lexical access and morphological analysis(词汇提取和形态学分析)。形态学分析将单词拆分为词素 (morphemes):lemma(词干) and affixes(词缀)。
- Grammatical analysis(语法分析): 通过词性标注，短句检测，句法分析消除可能影响发音的词性歧义。
- Phonetic translation 语音翻译:Transcription(转写) rules 处理单词。这些规则通常会根据一个字母的左右语境来生成器语音转写。

9.1 文本标准化 Text Normalization

- 过程
 1. 识别文本中的标记
 2. 将 token 分块为大小合理的部分
 3. 将 token 映射到单词
 4. 识别单词类型
- 核心目标
 1. 识别文本中的有效语言单位 tokens, 剔除无效信息
 2. 解决文本歧义 (如缩写, 数字, 符号的多义性)
 3. 将非标准表达 (数字, 缩写, URL) 转化为标准发音形式
- 分句 (sentence Segmentation)

解决"." 句号歧义性, 既可以表示句子的边界, 也可以表示单词的缩写。对于句点的消歧, 需要识别缩写词, 也要识别大写字母对应的是句首字母还是专有名词。
- tokens 标准化 (可以使用决策树进行学习)

最简单的分词形式是通过在空格和不属于缩写的标点符号处分割文本来实现。

非标准词指不符合常规拼写规则、无法直接发音的表达, 比如缩写, 数字, 符号, URL, 邮箱 (添加特殊 token type 标识)

规范拼写形式: 复合语言书写规范、可直接映射音素的单词形式 (MR. 映射为 Mister, 123 变为 one hundred and twenty-three)

非标准词属于分词后得到的语言单位, 在执行字素到音素 (grapheme-to-phoneme) 转换之前要扩展为规范的拼写形式 (orthographic form)

9.2 Grapheme to Phoneme Conversion(G2P)

- 字母, 字素, 音素
 1. 字母: 书面单词的视觉组成

- 2. 字素：代表音素的单个字母和字母组合
- 3. 音素：口腔发出的声音
- G2P 定义：将书面语的字素序列映射为口语的音素序列
- Orthographic depth 正字法深度
 - 1. 定义：文字系统中字素与音素对应关系的规则程度
 - 2. shallow orthographic 浅正字法：字素音素对应高度规则
 - 3. Deep orthographic 深正字法：字素音素对应不规则（同一字素多种发音/统一发音多种字素）
- 规则法 (letter-to-sound(LTS))
 - 1. 使用规则将文本转换为音素，通过前后语境编写字母组合的相关音素
 - 2. 优点：无限制词汇量，内存需求量大
 - 3. 缺点：规则编写复杂，难以覆盖所有例外情况
- 词典法 (Lexicon-Based)
 - 1. 预先构建单词-音素映射词典，并存储进文件中，转换时直接查询单词对应的音素序列。
 - 2. 需要构建 exceptions lexicon(例外词典) 将具有特殊发音的文本或者规则未涵盖的特殊常见文本存在例外字典中 (缩写，首字母缩略词，名字)。
 - 3. 优点：无需复杂语义判断
 - 4. 缺点：词汇量受限，未收录单词无法处理；内存需求量大
- 先词典，若没有单词，就使用规则法进行转换。
- G2P 问题
 - 1. Homophony（同音异义）
 - 2. Homograph disambiguation（同形异义词消歧）

9.3 Syntactic analysis 句法分析

- Homograph disambiguation 需要 syntactic analysis.
- 句法分析也可以用来确定适当的韵律特征.

9.4 Prosody Synthesis 韵律合成

- 韵律合成定义：韵律合成包括对短语进行语速，音高模式，停顿以及音素的强度和时长进行标注。
- 流程
 1. Prosodic Phrasing(韵律短句划分)
 - 将完整的 utterance 话语拆分为符合口语习惯的短语单元，确定停顿位置和时长
 - 停顿位置通过标点以及句法分析进行确定
 2. Accent Prediction(重音预测)
 - 确定短语中需要重读的音节
 - 为重音音节生成 pitch contour
 3. Prosodic feature generation(为每个音素分配韵律参数值)
 - Intonation(pitch)
 - (a) 避免单调的机器人的声音
 - (b) 情景主题
 - (c) 陈述句与疑问句
 - Rhythm(duration/length)
 - (a) 语速，停顿，重音
 - Intensity(loudness)
 - (a) 浊音强度随音高成正比例增加
 - (b) 话语接近结尾变弱
 - (c) 情绪状态